前面我们学习了三种基本数据结构:

■线性表

- 一般线性表(数据元素、关系、操作均无限制)
- 栈和队列(操作有限制:两端插入删除)
- 字符串(数据元素有限制带来操作对象变化)
- 数组(参与关系有限制:参与多个关系)
- 树和二叉树结构
- ■图结构

讲授和学习的方法:

- ■ADT的定义:
 - 数据结构的逻辑特性;
 - 数据结构上定义的操作;
- ■ADT的实现:
 - 逻辑结构的实现(存储结构)
 - •操作的实现(算法);
- ■ADT应用举例:

前面学习的每一种数据结构都定义了一 些常用的操作,如:初始化、访问某数据元素等等, 因此,研究操作的实现(不是操作的定义)即算法 与数据结构密不可分。

有两个操作在每个数据结构上一般都要定义, 而且是非常重要的:

- ■确定元素的位置——搜索(查找);
- ■将元素按某种顺序排列——排序(分类)

学习和掌握操作实现(算法)的基本思想、效率、优缺点

第七章 搜索(查找)

本章学习各种查找方法,了解算法的基本思想、效率、优缺点、适用范围等等。

7.1 基本概念

- 1. 查找: 在某一数据集合中查找数据元素是否存在, 若存在, 返回其位置, 否则, 返回失败信息。
- 2. 查找表: 被查找数据元素的集合,如果是逻辑结构上定义的操作,那么位置就是逻辑位置;如果有了存储结构,那么位置应该就是物理位置。因此,查找表一般是"数据结构+存储结构"
- 3. 查找表的种类

静态查找表:数据集合在查找前后不变(没有插入删除);

动态查找表:数据集合在查找后会改变(有插入删除);

7.1 基本概念

- 4. 关键码: 可以唯一地标识一个数据元素的数据项 (属性)。
 - •基于关键码的查找:结果唯一;
 - •基于一般属性的查找:结果可能不唯一;

5. 查找方法:

查找表不同,查找方法就会不同。有很多不同 的查找方法。

7.1 基本概念

6. 查找算法的评价:

空间:占用的辅助空间少;

时间:时间少。查找的基本操作是比较,因此

时间主要体现为比较次数。

查找成功:

最大比较次数——MSL(Maximum Serach Length) 平均比较次数——ASL(Average Serach Length)

查找失败:

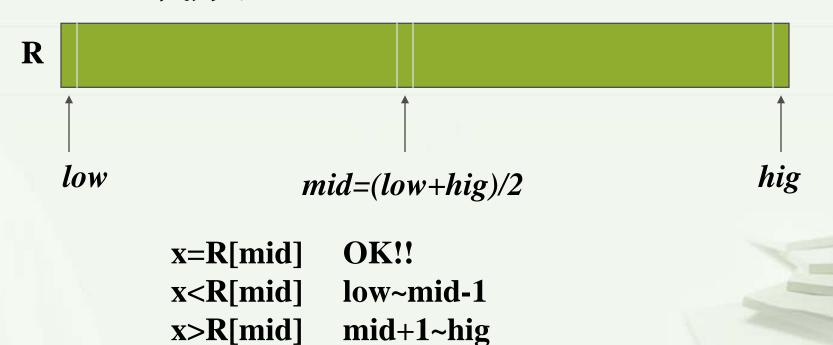
最大比较次数——MSL 平均比较次数——ASL

- 7.2.1 静态查找表是顺序或链式存储的线性表——顺序查找
 - 1. 查找表的要求: 线性表
 - 2. 查找方法:不断找前驱(或后继)即可
 - 3. 特点:

思想简单,对查找表要求少,适应面广; 比较次数较大O(n);

(考虑查找概率不相等时应该如何处理?)

- 7.2.2 静态查找表是*顺序存储的、有序的*线性表 ——折半查找(Fibonacci查找、插值查找)
 - 1. 查找表的要求: 顺序存储、有序的线性表
 - 2. 查找方法:

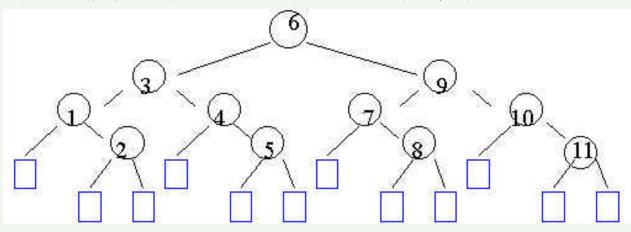


- 7.2.2 静态查找表是*顺序存储的、有序的*线性表 ——折半查找(Fibonacci查找、插值查找)
 - 3. 特点:

对查找表要求多; 比较次数较少O(log₂n);

折半查找的过程可以用一棵二叉树表示,称之为"折半 查找的判定树"。

例如: 折半查找在n=11 时的判定树如下:



- 7.2.3 静态查找表是二叉树
 - ——静态二叉排序树查找
- 1. 查找表的要求: 二叉分类树(二叉排序树)
- 2. 查找方法:

X与根比较:

相等: OK!

X<根: 在左子树上找

X>根: 在右子树上找

3. 特点:

类似折半,比较次数最大是树的深度;等概率时,深度为 log_2 n二叉排序树最好;不等概率时,概率高的应该靠近根。

- 7.2.4 静态查找表是分块索引表
 - ——分块查找(索引顺序查找)
- 1. 查找表的要求:顺序存储、分块有序;即:每一块中的结点不必有序,但块与块之间必须"按块有序";
- 2. 查找方法:
 - 先选取各块中的最大关键字构成一个索引表
 - 折半方法确定被查找元素可能所在的块;
 - 在块中采用顺序查找,确定元素是否存在;
- 3. 特点:

要建立索引表; 效率介于折半和顺序之间;

查找表本身是在查找过程中动态生成的,即对于给定值 key,若查找表中存在其关键码等于key的元素,则查找成功 返回,否则插入关键码等于key的元素。

动态查找表可以是线性表,也可以是树(二叉排序树)。 最常用的动态查找表是:二叉排序树。

查找方法:

若二叉排序树为空,则查找不成功,在二叉排序树中查入 该元素;否则

- 1) 若给定值等于根结点的关键字,则查找成功;
- 2) 若给定值小于根结点的关键字,则继续在左子树上进行查找;
- 3) 若给定值大于根结点的关键字,则继续在右子树上进行查找。

特点:

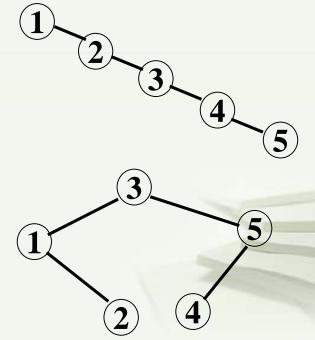
查找效率与构造出的二叉排序树的深度有关;

对于每一棵特定的二叉排序树,均可按照平均查找长度的定义来求它的ASL值,显然,由值相同的n个关键字构造所得的,不同形态的各棵二叉排序树的平均查找长度的值不同,甚至可能差别很大,例如:

由关键字序列1, 2, 3, 4, 5 构造而得的二叉排序树: ASL = (1+2+3+4+5) / 5 = 3

由关键字序列3,1,2,5,4构造而得的二叉排序树:

$$ASL = (1+2+3+2+3) / 5 = 2.2$$



7.3.1 平衡二叉树

■ 平衡二叉树的定义

1. 定义: 一棵二叉排序树是平衡的,当且仅当每个结点的左右子树的高度至多相差为1。由G.M.Adelson_Velskii和E.M.Landis给出的定义——AVL树。

递归定义:

- (1)空树是二叉排序树;
- (2)它的左右子树都是二叉排序树,且左右子树的高度最多相差为1;
- 2.平衡因子:

左子树的高度一右子树的高度,即

 $BF(t)=H_l-H_r$

平衡二叉树中,对任意结点: BF=1 、 0 -1

7.3.1 平衡二叉树

- 平衡二叉树的定义
- 3.平衡二叉树的特点: 其深度和 log_2 n同数量级,即AVL树的平均查找长度为 $O(log_2$ n);
- 4. AVL树的构造和调整过程:
 - (1) 基本原则:

按照二叉排序树的构造方法,构造过程中判断是否为平衡二叉树(平衡因子),是,则继续构造;否则,按一定的原则(保持是二叉排序树和平衡)将其调整为平衡,然后继续。

7.3.1 平衡二叉树

- 平衡二叉树的定义
 - (2)插入过程中的调整原则:

二叉排序树在插入前平衡,插入一个结点后如果失去平衡,则至少有一个结点的平衡因子变为+2或-2。

若平衡因子=+2,则左分支高于右分支;

若平衡因子=-2,则右分支高于左分支;

分为4种情况,分别进行调整:

LL型: 在左分支的左子树上插入后,失去平衡,BF=2

LR型: 在左分支的右上子树插入后,失去平衡,BF=2

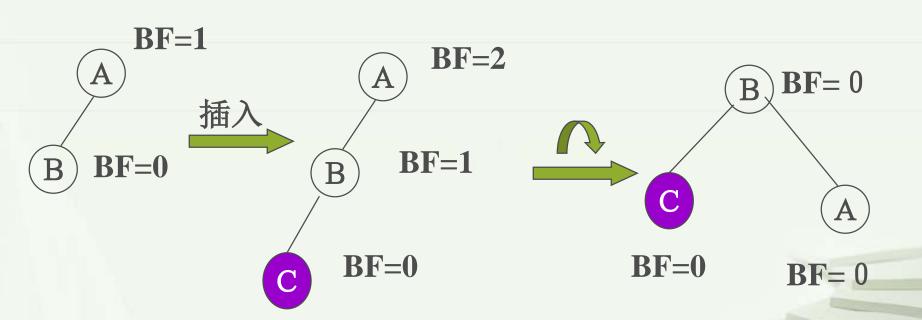
RR型: 在右分支的右子树上插入后, 失去平衡, BF=-2

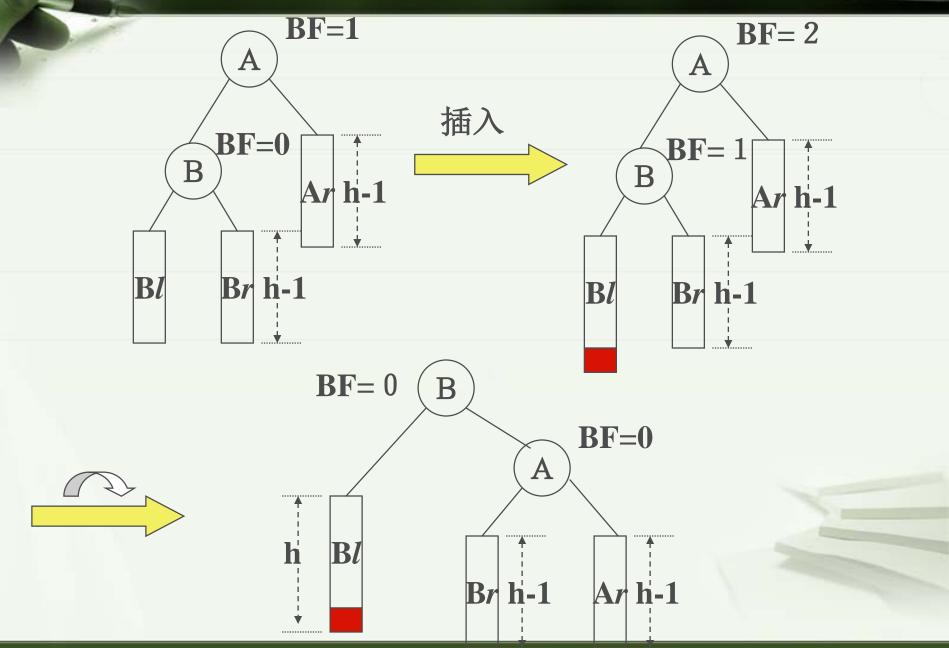
RL型: 在右分支的左子树上插入后,失去平衡, BF=-2

7.3.1 平衡二叉树

LL型:

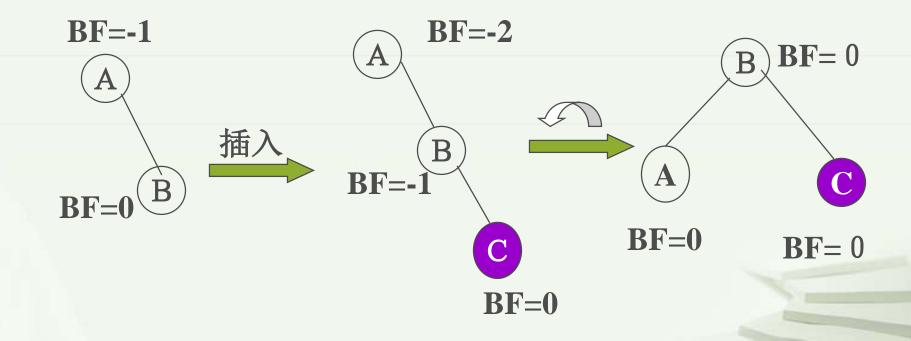
特殊地:

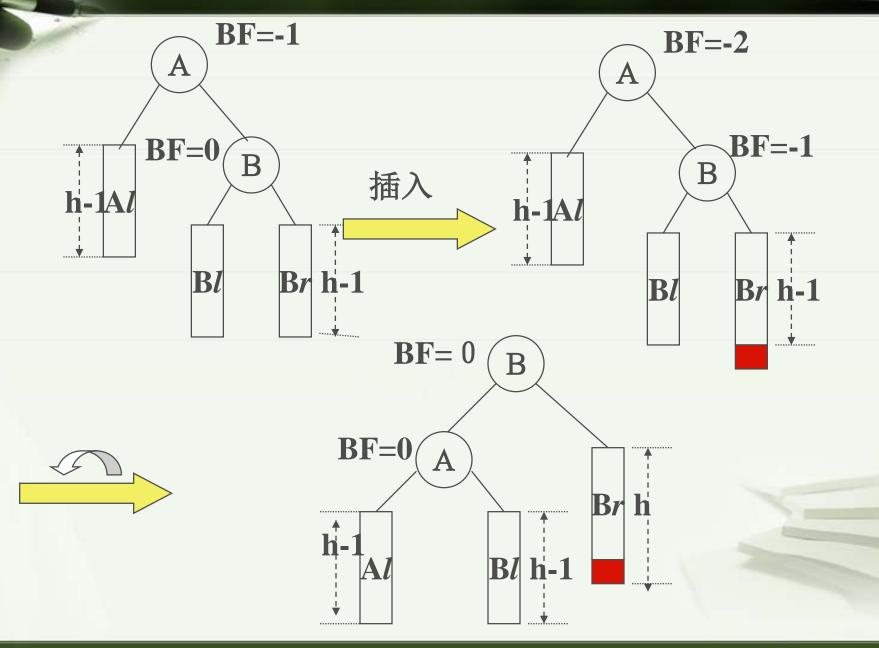




RR型:

特殊地:

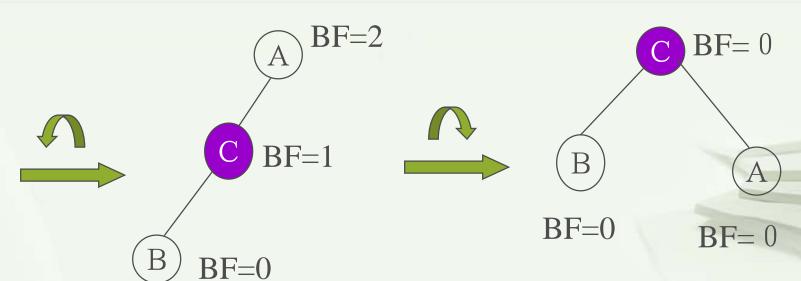


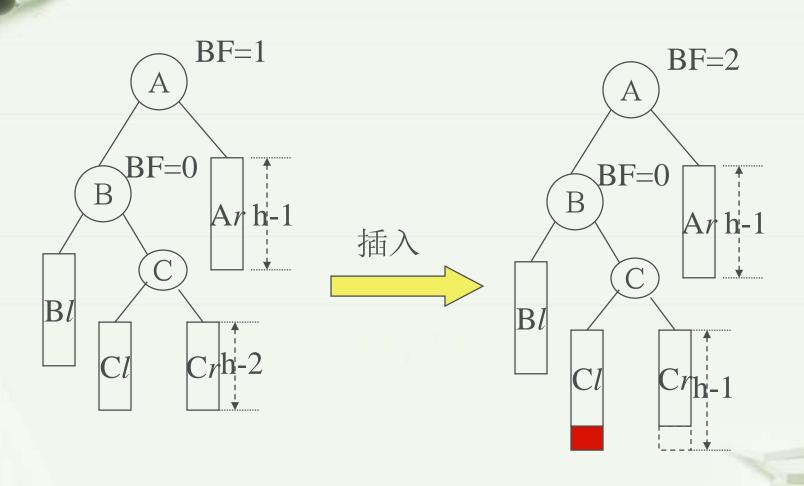


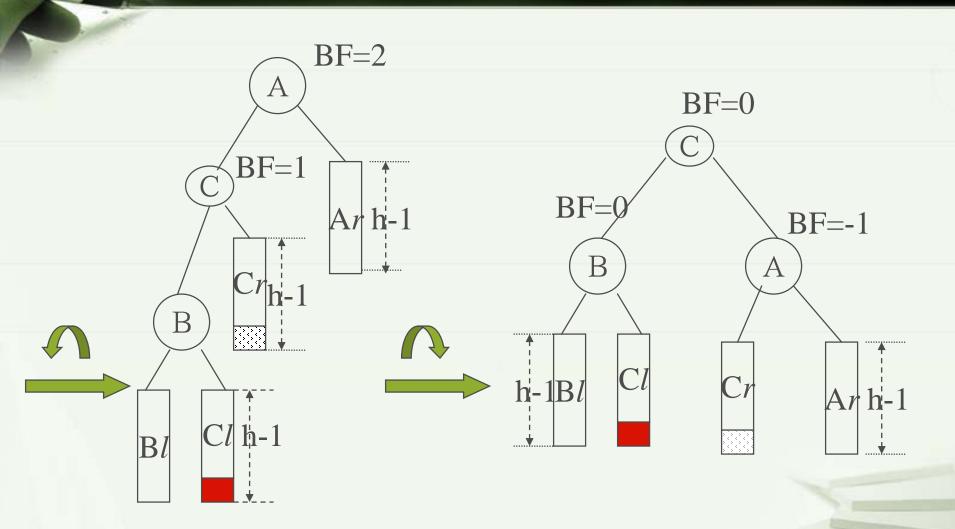
LR型:

特殊地:



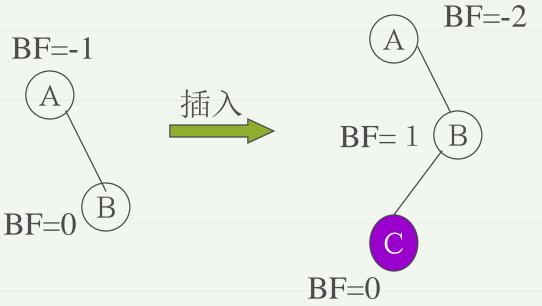


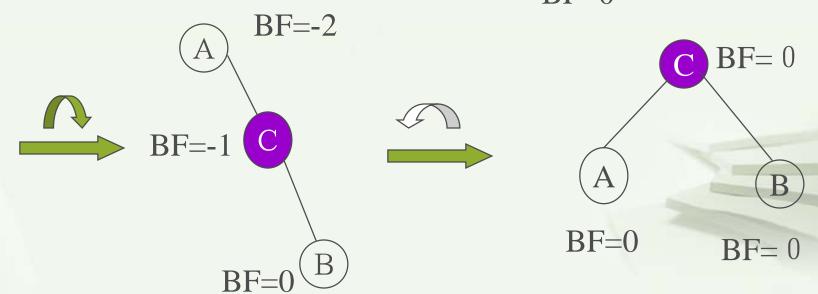


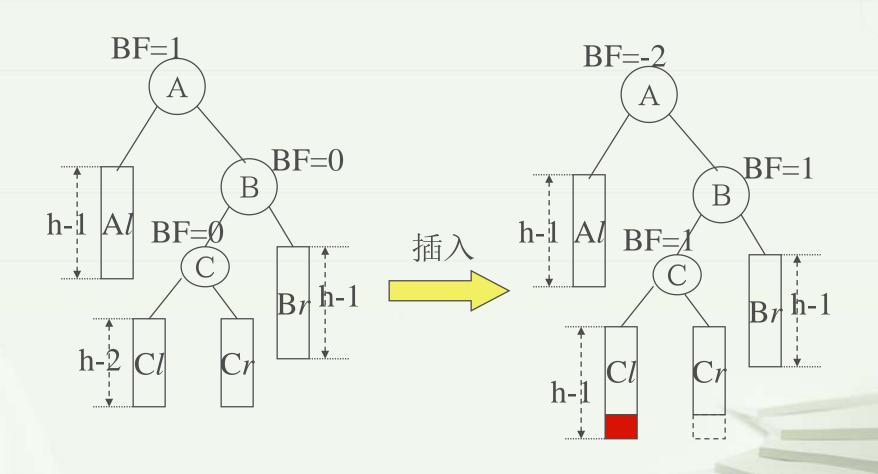


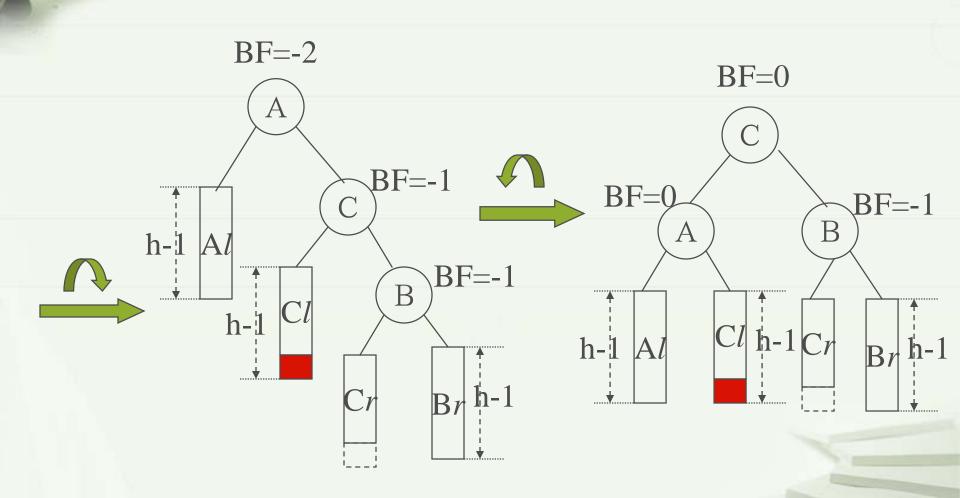
RL型:

特殊地:









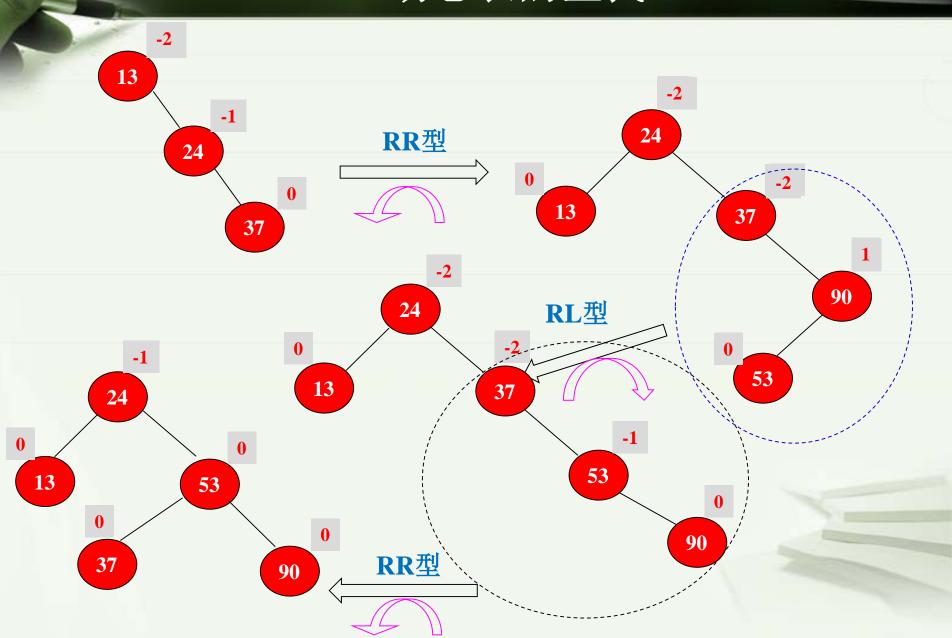
■ 平衡二叉树上的查找

- 1. 查找过程: 同静态二叉排序树一样!
- 2.效率分析:

查找过程中和给定值进行比较的关键字的个数不超过平衡树的深度。

假设深度为h的二叉平衡树上所含结点数的最小值为 N_h ,则显然 $N_h = N_{h-1} + N_{h-2} + 1$ 由此可以推导出: $h \approx log(n)$ 因此,在平衡树上进行查找的时间复杂度为O(log(n))

举例: 有下列元素,构造平衡二叉树 13,24,37,90,53



7.4.1 哈希技术概述

- "哈希"是英文HASH的音译,又翻译作"散列"、"杂凑"等。
- 1. 哈希技术的提出背景:

我们前面介绍的各种查找方法,其基本操作是"比较"即通过比较得到元素的位置。那么,有没有不用"比较"的查找方法?

如果有一个函数,它能够根据要查找的关键字直接计算 出要查找元素的地址,该地址的内容为空,则查找的元素不 存在,否则,查找成功。显然,这样的查找不需要比较!

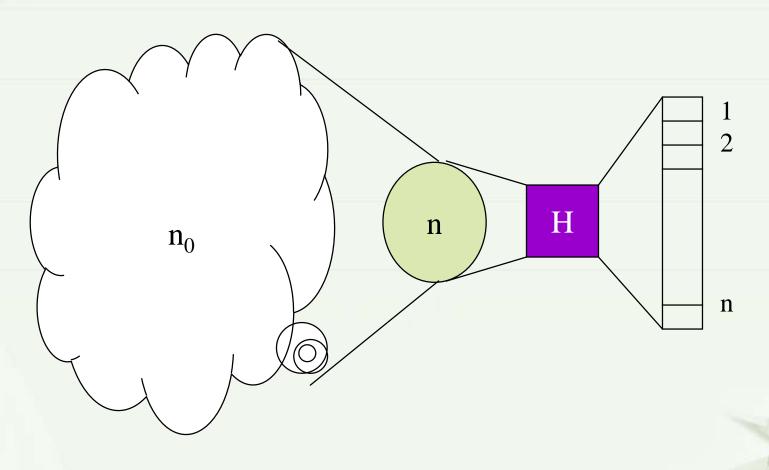
基于这种思想的技术就是HASH查找技术

- 7.4.1 哈希技术概述
 - 2. 什么情况下使用HASH技术?

如果问题的数据元素已知,很容易地建立数据元素和存储地址之间的一一映射函数关系,HASH技术是很简单的,HASH技术也就失去了意义,实际上HSAH技术是针对下类问题的:

问题的数据元素的可用集合很大,而一个问题的具体数据元素是取自该可用集合的一个很小的任意一个集合,因此,解决问题时需要的空间大小是根据小集合大小确定的,但是,如果要建立函数映射,函数的定义域应该是大集合,而值域是由小集合确定的,因此建立这样的一一映射是很困难的,所以才有了HASH技术。

7.4.1 哈希技术概述



7.4.1 哈希技术概述

3. HASH类问题的描述:

假设问题可能用到的关键字集合为U, $|U|=n_0$,即该集合的元素个数为 n_0 ,而一个问题实际用到的关键字集合为S,|S|=n, $n<<<< n_0$,且S是取自U的任意一个子集合,表示为 $\{R_1,R_2,R_3,...R_n\}$,其关键字集合为 $\{K_1,K_2,...,K_n\}$;T是解决问题需要的连续空间,它由m个存储单元组成,表示为T[0..m-1], $m\geq n$ 。

有一个函数H,其定义域是 $key \in U$,值域是 $i \in 0..m-1$,它将关键字映射到存储空间地址上;

H(key)=i key $\in U$, $i\in 0..m-1$

- 7.4.1 哈希技术概述
- 4. 有关基本概念:
- (1) HASH函数:将元素按照关键字映射出存储空间地址的函数,记作:H(key)
- (2) HASH地址:由HSAH函数计算出的数据元素的存储地址;
- (3) HASH表:存储元素的连续地址空间T;
- (4) HASH造表:利用HASH函数将元素存储到HASH表中的过程;
 - (5) HASH表的填充度(装填因子):

7.4.1 哈希技术概述

- (6) 冲突:由于HASH函数的定义域是U,而S是U的任意一个小子集,映射地址空间是由S的大小确定的,因此,对于不同的关键字可能得到相同的HASH地址,即:若 key1≠key2,而 H(key1)=H(key2),则称为冲突。
 - (7) 同义词: 若 H(key1)=H(key2),则key1和key2互称 为同义词。
- 5. HASH技术的关键:
 - **▲ HASH函数的构造**
 - ▲ 解决冲突的方法

7.4.2 哈希函数的构造方法

函数设计目标:使通过哈希函数得到的n个数据元素的哈希地址尽可能均匀地分布在m个连续内存单元上,同时使计算过程尽可能简单以达到尽可能高的时间效率。

常用的哈希函数构造方法有:

1. 除法取余

- 2. 直接定址法
- 3. 数字分析法
- 4. 折叠法
- 5. 平方取中

7.4.2 哈希函数的构造方法

除留余法:

H(key)= key MOD P P是不大于m的素数, m是HASH表的长度;

特点:这是一种最简单、最常用的方法。

* P的选择很重要,选择不好会产生同义词;

*P一般取位素数或不包含小于20的质数的合数;

7.4.3 冲突的解决方法

解决冲突的策略分为两类:

- (1) 闭散列方法(Closed Hashing):同义词放在HASH表中的其他位置; (Open addressing,又称为开地址法)
- (2) 开散列方法(Open Hashing):同义词放在HASH表之外的空间中; (Separate chaining,又称为拉链法)
 - 1、开放定址法: (闭散列) 发生冲突后,按一定的原则寻找新的地址: Hi=(H(key)+di) MOD m i=1,2,...,k

HI=(H(Key)+dI) MOD m I=1,2,...,K
di为增量,m为HASH表的长度;
di的取法:

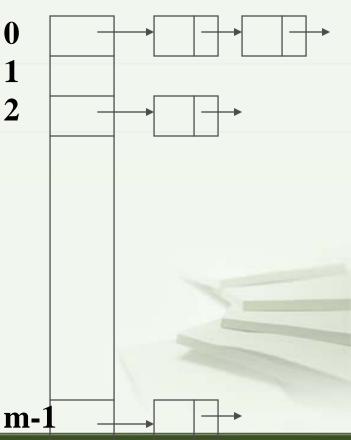
线性探测: di=1,2,3,...,m-1

二次探测: $di=1^2,-1^2,2^2,-2^2,...,\pm k^2$

7.4.3 冲突的解决方法

2、再造HASH法: (闭散列)
Hi=RHi(key)
用一系列HASH函数计算地址

3、链地址法: (开散列) 将同义词存放在同一个链表中;



7.4.3 冲突的解决方法

4、建立公共溢出区法: 除了HASH表外,开辟一个公共溢出区,一旦冲突,将同义词放入公共溢出区;



溢出表: 012 v

- 7.4.4 哈希查找
- 1、哈希查找的方法

给定关键字 k:

- (1) 用给定的HASH函数计算出k的HASH地址; i=H(key)
- (2) 若该地址为空,则查找失败; 否则,若 T[i]=k,则查找成功,返回地址; 否则,按HASH造表时解决冲突的方法计算出新的地址;
- (3) 重复(2) 直到查找成功或失败。

2、性能分析:

若没有冲突: O(1); 有冲突,性能与下列因素有关:

> HASH函数 解决冲突的方法 装填因子

7.4.4 哈希查找

已知有一组元素: 19,14,23,01,68,20,84,27,55,11,10,79

HASH函数为: H(key)= key MOD 13, HASH表长度为16,

构造HASH表,进行HASH查找。

(1) 线性探测法解决冲突 Hi=(H(key)+di) MOD 15 di=1,2,3,...,m-1

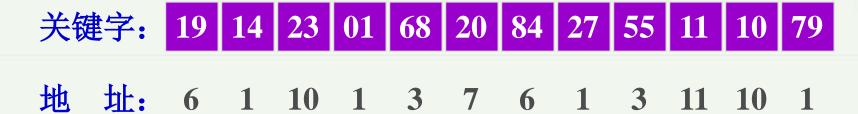
关键字:	19	14	23	01	68	20	84	27	55	11	10	79

地 址: 6 1 10 1 3 7 6 1 3 11 10 1

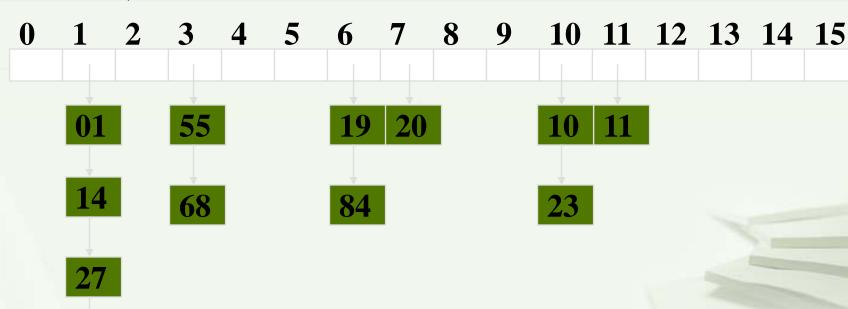
HASH表:



(2) 链地址法解决冲突



HASH表:



7.4.4 哈希查找

查找元素 27: 需要比较多少次?

查找元素 9: 需要比较多少次?

