

第六章常微分方程的数值解法

§6.1 引言

零. 基础知识回顾

1. 微分方程

有一个或多个导数及其函数的方程式称为微分方程，微分方程中含有参数，未知函数和未知函数的导数。微分方程分为两类，常微分方程和偏微分方程。未知函数是一元函数的是常微分方程，只有一个自变量参数；未知函数是多元函数的微分方程称为偏微分方程，偏微分方程有一个以上自变量参数。微分方程中出现的未知函数的最高阶导数的阶数，称为微分方程的阶。微分方程的解是满足微分方程的函数。微分方程求解分为求通解和特解。通解是满足微分方程的函数表达式，通解中存在一些待定的常数，特解是通过初值条件确定了常数值得到的微分方程的解。

例


$$\frac{dy}{dx} = 2x + 1$$

通解： $y = x^2 + x + c$

结合其他条件，可以解除特解。如有条件说要求微分方程满足 $\int_0^1 y dy = 4$ 的解，把通解代入

得 $y = x^2 + x + \frac{35}{12}$ ；或者要满足通过点(1,2)，把通解代入得 $y = x^2 + x$ 。

一阶微分方程的通解，是 xy 空间上的一簇曲线，称之为微分方程的积分曲线簇。一阶微分方程的特解，是 xy 空间上的一条曲线，称之为微分方程的积分曲线。本课程只讨论一阶常微分方程数值解法。



2. 两类求定解问题

定解指因变量和/或其导数在某些点是已知的，称为约束条件。实际中求解常微分方程的所谓定解问题有两类：初值问题和边值问题

1) 边解问题

已知区间端点边界约束条件，在自变量的任一非初值上，已知函数值和/或其导数值，如

$$\begin{cases} y'' = f(x, y, y') \\ y(a) = \alpha, y(b) = \beta \end{cases} \quad \text{求解 } y$$

2) 初值问题

约束条件：在自变量的初值上已知函数值，如

$$\begin{cases} y' = f(x, y) \\ y(x_0) = y_0 \end{cases} \Rightarrow \begin{cases} \frac{dy}{dx} = f(x, y) \\ y(x_0) = y_0 \end{cases}$$

解常微分方程的初值问题，求函数 $y(x)$ 满足下列常微分方程

$$y'(x) = f(x, y)$$

和初值条件

$$y(x_0) = y_0$$

$$\text{或者} \begin{cases} y'(x) = f(x, y) & (6-1) \\ y(x_0) = y_0 & (6-2) \end{cases}$$

就是求一条过 (x_0, y_0) 点的积分曲线。

$$\text{例：方程 } xy' - 2y = 4x \Rightarrow y' = \frac{2y}{x} + 4$$

$$\text{令： } f(x, y) = \frac{2y}{x} + 4$$

且给出初值 $y(1) = -3$

就是一阶常微分方程的初值问题

$$\begin{cases} \frac{dy}{dx} = f(x, y) = \frac{2y}{x} + 4 \\ y(1) = -3 \end{cases}$$

一阶微分方程的边值问题通常是转换成初值问题来求解。所以本课程只讨论一阶微分方程的初值问题的数值解法。

3. 解存在定理

定理 6.1 对初值问题(6-1)(6-2)，若 $f(x, y)$ 在区域

$$G = \{a < x < b, |y| < \infty\}$$

内连续，且关于 y 满足李普希兹(Lipschitz)条件，即存在常数 L ，

$$\text{使 } |f(x, y_1) - f(x, y_2)| \leq L|y_1 - y_2| \quad (6-3)$$

对 G 中任意两个 y_1, y_2 均成立，其中 L 是与 x, y 无关的常数，则初值问题(6-1)(6-2)在 (a, b) 内存在唯一解，且解是连续可微的，其中 L 称为 Lipschitz 常数

一. 问题提出

由于很多微分方程的解不能用初等函数来表示；并且有时即使能够用解析式表示其解，由于表达式过于复杂，所以计算量太大而不实用。所以微分方程求解析解是比较困难的。解决这个问题基本思路就是近似，有两种方法，一种是近似解析解，就是满足精度要求的解的简单的近似表达式；另一种方法就是数值方法来求解，一般只要求得到若干个点上的解函数的近似值，也就是得到解函数的表格函数形式，也称之为数值解，数值解法适于计算机进行求解。

求解常微分方程初值问题的数值解，采用离散化思想，在解区间 $[a, b]$ 上离散采样 $a = x_0 < x_1 < \cdots < x_n = b$ ，然后通过算法计算出对应点准确解 $y(x_i)$ 的近似值 $y_0, y_1, y_2, \cdots, y_n$ 。通常取离散点为等距的，即 $x_{i+1} - x_i = h, i = 0, 1, 2, \cdots, n-1$ ， h 称为步长。

四. 数值解法含义

常微分方程数值求解就是将常微分方程离散化，建立差分方程，给出解在一些离散点上的近似值。首先是区间是 $[a, b]$ 离散化：取 $a = x_0 < x_1 < \cdots < x_n = b, h_k = x_{k+1} - x_k$ ，等距时 $h = (b - a)/n$ ， h 称为步长。数值方法求得 $y(x)$ 在每个节点 x_k 上 $y(x_k)$ 的近似值，用 y_k 表示，则 y_0, y_1, \cdots, y_n 称为微分方程的数值解。

通常采用递推公式由 y_0, y_1, \cdots, y_i 推出 y_{i+1} 。所以常微分方程的各种方法的本质是构造递推公式。

初值问题的常见解法按照使用之前求得的解元素的个数，分为两类：单步法和多步法。单步法是利用前一个单步的信息(一个点)，在 $y = f(x)$ 找下一点 y_i ，包括 Euler 法，Runge-Kutta 法等。多步法利用一个以上的前面离散点信息，求 $y = f(x)$ 的下一点 y_i ，常用迭代法，如改进 Euler 法，Adams 法。

§6.2 Euler 方法

一. Euler 方法

设区间 $[a, b]$ 上给定 $n + 1$ 个等距节点 $x_i = a + ih (i = 0, 1, \cdots, n)$ ，其中 $h = \frac{b-a}{n}$ 。

由差分公式 $\frac{y(x_{i+1}) - y(x_i)}{h} \approx y'(x_i) = f(x_i, y_i)$ 导出 $y(x_{i+1}) \approx y(x_i) + hf(x_i, y_i)$

用 x_i 处近似值 y_i 代替 $y(x_i)$ ，则得到初值问题(6-1)(6-2)递推公式

$$\begin{cases} y_0 = y(x_0) \\ y_{i+1} = y_i + hf(x_i, y_i) \end{cases} \quad i = 0, 1, 2, \cdots, n$$

称为微分方程解初值问题的 Euler 方法。

Euler 方法计算过程如下：

$$x = x_0 : y(x_0) = y_0$$


$$x = x_1 : y_1 = y_0 + hf(x_0, y_0); \quad y(x_1) = y_1$$

$$x = x_2 : y_2 = y_1 + hf(x_1, y_1); \quad y(x_2) = y_2$$

.....

$$x = x_n : y_n = y_{n-1} + hf(x_{n-1}, y_{n-1}); \quad y(x_n) = y_n$$

Euler 方法的几何意义



从 $p_0(x_0, y_0)$ 出发, 以 $f(x_0, y_0)$ 为斜率做一条直线与直线 $x = x_1$ 交于点 $p_1(x_1, y_1)$, 即 $y_1 = y_0 + hf(x_0, y_0)$;

从 $p_1(x_1, y_1)$ 出发, 以 $f(x_1, y_1)$ 为斜率做一条直线与直线 $x = x_2$ 交于点 $p_2(x_2, y_2)$, 即 $y_2 = y_1 + hf(x_1, y_1)$;

... ..

从 $p_{n-1}(x_{n-1}, y_{n-1})$ 出发, 以 $f(x_{n-1}, y_{n-1})$ 为斜率做一条直线与直线 $x = x_n$ 交于点 $p_n(x_n, y_n)$, 即 $y_n = y_{n-1} + hf(x_{n-1}, y_{n-1})$;

得到解曲线的一条近似曲线, 是一条折线 $p_0p_1p_2 \cdots p_n$ 。故 Euler 法也称 Euler 折线法

Euler 法是单步法

Euler 法是用 y_i 通过递推公式 $y_{i+1} = y_i + hf(x_i, y_i)$, 计算 y_{i+1} 的; 所以在计算 y_{i+1} 时, 只使用了 y_i 的函数值 y_i 和导数值 $f(x_i, y_i)$, 故为 Euler 方法是一种单步法。

例 1: 用 Euler 法求解方程 $\begin{cases} y' = -2xy \\ y(0) = 1 \end{cases}, 0 \leq x \leq 1.2, h = 0.2$

解: 由题意知:

$$f(x, y) = -2xy, h = 0.2$$

$$x_0 = 0, x_1 = 0.2, x_2 = 0.4, x_3 = 0.6, x_4 = 0.8, x_5 = 1.0, x_6 = 1.2$$

Euler 法的递推公式为:

$$y_{i+1} = y_i + hf(x_i, y_i) = y_i + 0.2(-2x_i \times y_i) = (1 - 0.4x_i)y_i$$

$$\text{所以: } y_1 = y_0 + hf(x_0, y_0) = (1 - 0.4x_0)y_0 = 1,$$

$$y(x_1) \approx y_1 = 1$$

$$y_2 = y_1 + hf(x_1, y_1) = (1 - 0.4x_1)y_1 = 0.920000$$

$$y(x_2) \approx y_2 = 0.920000$$

所求值用下表列出, 并与精确值对比

x_i	y_i	$y(x_i)$
0	1	1
0.2	1	0.960789
0.4	0.920000	0.852144
0.6	0.772800	0.697676
0.8	0.587322	0.527792
1.0	0.399383	0.367879
1.2	0.239630	0.236938

例 2: 用 Euler 法解初值问题 $\begin{cases} y' = -y - xy^2 \\ y(0) = 1 \end{cases} (0 \leq x \leq 0.6)$

取步长 $h = 0.2$, 计算过程保留 4 位小数

$$\text{解: } f(x, y) = -y - xy^2, h = 0.2$$

Euler 递推公式:

$$y_{i+1} = y_i + hf(x_i, y_i) = y_i + 0.2(-y_i - x_i \times y_i^2) = 0.2(4 - x_i \times y_i)y_i$$

$$i = 0, x_0 = 0, y_0 = 1$$

$$y(x_1) = y(0.2) \approx y_1 = 0.2(4 - x_0 \times y_0)y_0 = 0.2 \times (4 - 0 \times 1) = 0.8$$

$$i = 1, x_1 = 0.2, y_1 = 0.8$$

$$y(x_2) = y(0.4) \approx y_2 = 0.2 \times 0.8 \times (4 - 0.2 \times 0.8) = 0.6144$$

$$i = 2, x_2 = 0.4, y_2 = 0.6144,$$

$$y(x_3) = y(0.6) \approx y_3 = 0.2 \times 0.6144 \times (4 - 0.4 \times 0.6144) = 0.4613$$

隐式 Euler 法 (implicit Euler method)

使用向后差分来近似导数

$$y'(x_{i+1}) = \frac{y(x_{i+1}) - y(x_i)}{h}$$

$$y(x_{i+1}) = y(x_i) + hy'(x_{i+1}) = y(x_i) + hf(x_{i+1}, y_{i+1})$$

$$y_{i+1} = y_i + hf(x_{i+1}, y_{i+1}) \quad (i = 0, 1, 2, \dots, n-1)$$

由于未知数 y_{i+1} 同时出现在等式的两边, 所以从公式中不能直接计算出 y_{i+1} , 需要解这个方程, 解出 y_{i+1} 。可以用迭代法来求解这个方程; 迭代法一般需要给定一个初值, 所以通常先用显式公式计算一个初值, 再迭代法通过解方程得到更精确的 y_{i+1} 。

显式(explicit)与隐式(implicit)

显式 : 递推公式中, 从由 y_i 组成的公式中直接得到 y_{i+1} ;

显式 Euler 方法 : 递推公式 $y_{i+1} = y_i + hf(x_i, y_i)$, 直接计算得到 y_{i+1} , 称为显式 Euler 公式;

隐式 : 从由包含 y_{i+1} 组成的方程中, 求得到 y_{i+1} ;

隐式 Euler 方法 : 递推公式 $y_{i+1} = y_i + hf(x_{i+1}, y_{i+1})$, 由于未知数 y_{i+1} 同时出现在等式的两边, 不能直接得到。是一个方程, 通过求解方程得到 y_{i+1} , 故称为隐式 Euler 公式。

例: 用 Euler 法解初值问题
$$\begin{cases} \frac{dy}{dx} = 1 - xy \\ y(0) = 0 \end{cases} \quad (0 < x < 1)$$

取步长 $h = 0.2$, 计算过程保留 4 位小数

解: 因为 $f(x, y) = 1 - xy$

$$\text{Euler 公式为 } y(x_{i+1}) \approx y_{i+1} = y_i + hf(x_i, y_i) = y_i + 0.2(1 - x_i \times y_i) \\ (i = 0, 1, 2, 3, 4, 5)$$

$$\text{当 } i = 0, \text{ 即 } x_0 = 0.0 \text{ 时, } y_1 = 0 + 0.2(1 - 0 \times 0) = 0.2$$

$$\text{当 } i = 1, \text{ 即 } x_1 = 0.2 \text{ 时, } y_2 = 0.2 + 0.2(1 - 0.2 \times 0.2) = 0.3920$$

$$\text{当 } i = 2, \text{ 即 } x_2 = 0.4 \text{ 时, } y_3 = 0.392 + 0.2(1 - 0.4 \times 0.392) = 0.56064$$

$$\text{当 } i = 3, \text{ 即 } x_3 = 0.6 \text{ 时, } y_4 = 0.56064 + 0.2(1 - 0.6 \times 0.56064) = 0.6933632$$

$$\text{当 } i = 4, \text{ 即 } x_4 = 0.8 \text{ 时, } y_5 = 0.6933632 + 0.2(1 - 0.8 \times 0.6933632) = 0.782425088$$

列表计算如下:

i	0	1	2	3	4	5
x_i	0	0.2	0.4	0.6	0.8	1
y_i	0.0000	0.200	0.3920	0.5606	0.6934	0.7824

例：利用 Euler 方法求解初值问题 $\begin{cases} y' = \frac{1}{1+x^2} - 2y^2 \\ y(0) = 0 \end{cases} \quad (0 \leq x \leq 2)$ 的数值解。此问题的精确

解是 $y(x) = \frac{x}{1+x^2}$

解：Euler 公式为 $y(x_{i+1}) \approx y_{i+1} = y_i + hf(x_i, y_i) = y_i + h \left(\frac{1}{1+x_i^2} - 2y_i^2 \right)$

递推初值为 $y_0 = y(0) = 0$

分别取步长 $h = 0.2, 0.1, 0.05$ ，计算结果如下表

h	x_i	y_i	$y(x_i)$	$y(x_i) - y_i$
$h=0.2$	0.00	0.00000	0.00000	0.00000
	0.40	0.37631	0.34483	-0.03148
	0.80	0.54228	0.48780	-0.05448
	1.20	0.52709	0.49180	-0.03529
	1.60	0.46632	0.44944	-0.01689
	2.00	0.40682	0.40000	-0.00682
$h=0.1$	0.00	0.00000	0.00000	0.00000
	0.40	0.36085	0.34483	-0.01603
	0.80	0.51371	0.48780	-0.02590
	1.20	0.50961	0.49180	-0.01781
	1.60	0.45872	0.44944	-0.00928
	2.00	0.40419	0.40000	-0.00419
$h=0.05$	0.00	0.00000	0.00000	0.00000
	0.40	0.35287	0.34483	-0.00804
	0.80	0.50049	0.48780	-0.01268
	1.20	0.50073	0.49180	-0.00892
	1.60	0.45425	0.44944	-0.00481
	2.00	0.40227	0.40000	-0.00227

二. 梯形公式

对初值问题中的 $y' = f(x, y)$ 两边在 (x_i, x_{i+1}) 上求积分

$$\int_{x_i}^{x_{i+1}} y' dx = \int_{x_i}^{x_{i+1}} f(x, y) dx$$

$$y(x_{i+1}) = y(x_i) + \int_{x_i}^{x_{i+1}} f(x, y(x)) dx$$

对右侧积分采用梯形求积公式，则有

$$y(x_{i+1}) = y(x_i) + \frac{h}{2} [f(x_i, y(x_i)) + f(x_{i+1}, y(x_{i+1}))]$$

得出，常微分方程初值问题的梯形公式

$$y_{i+1} = y_i + \frac{h}{2} [f(x_i, y_i) + f(x_{i+1}, y_{i+1})]$$

$$(i = 0, 1, 2, \dots, n-1)$$

由于梯形公式左右两侧都有 y_{i+1} ，所以要通过求解该方程，得出 y_{i+1} 。故梯形公式是隐式公式。通过迭代法解方程求解 y_{i+1} ，迭代的初值通过 Euler 显式公式确定，迭代次数由计算误差决定。

三 Euler 预报校正法(/* predictor-corrector method */)

前面介绍了显式 Euler 公式，隐式 Euler 公式和梯形公式。这三个方法中，显式 Euler 公式简洁，计算也简单，但是结果的精度低；隐式 Euler 公式和梯形公式都需要解方程才能得到函数值，所以计算相对复杂；但是计算量较大，并且隐式 Euler 公式的精度也比较低。所以对这几个方法进行综合，将 Euler 公式和梯形公式综合使用可得到改进的 Euler 公式。

改进 Euler 法(modified Euler's method)

Step 1: 先用显式 Euler 公式作预测，算出 $\bar{y}_{i+1} = y_i + hf(x_i, y_i)$

Step 2: 再将 \bar{y}_{i+1} 代入隐式梯形公式的右边作校正，得到

$$y_{i+1} = y_i + \frac{h}{2}[f(x_i, y_i) + f(x_{i+1}, \bar{y}_{i+1})]$$

$$y_{i+1} = y_i + \frac{h}{2}[f(x_i, y_i) + f(x_{i+1}, y_i + hf(x_i, y_i))]$$

$$(i = 0, 1, \dots, n-1)$$

故改进 Euler 法为：

$$\begin{cases} \bar{y}_{i+1} = y_i + hf(x_i, y_i) \\ y_{i+1} = y_i + \frac{h}{2}[f(x_i, y_i) + f(x_{i+1}, \bar{y}_{i+1})] \\ y_0 = \alpha \end{cases}$$

$$(i = 0, 1, \dots, n-1)$$

当 y_i 已知时，通过第一式算出初值 \bar{y}_{i+1} ，再代入第二式进行方程求解，可以进行一次校正；也可以反复校正，迭代求解得到更精确解；

可以证明当 $1 < \frac{n}{2} \left| \frac{\partial f}{\partial y} \right| \leq 2$ 时，改进 Euler 法迭代收敛。

$$\begin{cases} \bar{y}_{i+1} = y_i + hf(x_i, y_i) \\ y_{i+1} = y_i + \frac{h}{2}[f(x_i, y_i) + f(x_{i+1}, \bar{y}_{i+1})] \\ y_0 = \alpha \end{cases}$$

将 $y_{i+1} = y_i + \frac{h}{2}[f(x_i, y_i) + f(x_{i+1}, \bar{y}_{i+1})]$ 中的 $f(x_i, y_i)$ 定义为 K_1 ；公式中的 $f(x_{i+1}, \bar{y}_{i+1})$ 是在

(x_{i+1}, \bar{y}_{i+1}) 处的导数值，而 $x_{i+1} = x_i + h$ ， $\bar{y}_{i+1} = y_i + hf(x_i, y_i) \xrightarrow{K_1=f(x_i, y_i)} y_i + hK_1$ ，令 $K_2 =$

$f(x_i + h, y_i + hK_1)$ 所以 $y_{i+1} = y_i + \frac{h}{2}[f(x_i, y_i) + f(x_{i+1}, \bar{y}_{i+1})] = y_i + \frac{h}{2}[K_1 + K_2]$ 。

通过这样的代换，改进 Euler 方法也可以写成：

$$\begin{cases} y_{i+1} = y_i + \frac{h}{2}[K_1 + K_2] \\ K_1 = f(x_i, y_i) \\ K_2 = f(x_i + h, y_i + hK_1) \\ y_0 = \alpha \end{cases}$$

$$(i = 0, 1, \dots, n-1)$$

例：求初值问题 $\begin{cases} y' = y - \frac{2x}{y} \\ y(0) = 1 \end{cases}$ ($0 \leq x \leq 1$) 的数值解，取步长 $h = 0.1$ (精确解为 $y(x) = 1 + 2x$)

解：(1) 利用 Euler 公式 $\begin{cases} y_{i+1} = y_i + hf(x_i, y_i) = y_i + 0.1 \left(y_i - \frac{2x_i}{y_i} \right) \\ y_0 = 1 \end{cases}$

$$\begin{cases} y_{i+1} = 1.1y_i + 0.2 \frac{x_i}{y_i} \\ y_0 = 1 \end{cases} \quad i = 0, 1, \dots, 9$$

(2) 利用改进 Euler 公式 $\begin{cases} y_{i+1} = y_i + \frac{h}{2} [K_1 + K_2] \\ K_1 = f(x_i, y_i) \\ K_2 = f(x_i + h, y_i + hK_1) \\ y_0 = \alpha \end{cases}$

$$\begin{cases} y_{i+1} = y_i + \frac{h}{2} [K_1 + K_2] \\ K_1 = y_i - \frac{2x_i}{y_i} \\ K_2 = y_i + 0.1K_1 - \frac{2(x_i+0.1)}{y_i+0.1K_1} \\ y_0 = 1 \end{cases} \quad i = 0, 1, \dots, 9$$

计算结果如下：

i	x_i	Euler 方法 y_i	改进 Euler 法 y_i	精确解 $y_i(x_i)$
0	0.0	1	1	1
1	0.1	1.1	1.095909	1.905445
2	0.2	1.191818	1.184096	1.183216
3	0.3	1.277438	1.266201	1.264991
4	0.4	1.358213	1.343360	1.344641
5	0.5	1.435133	1.416402	1.414214
6	0.6	1.508966	1.485956	1.483240
7	0.7	1.580338	1.552515	1.549193
8	0.8	1.649783	1.616476	1.612452
9	0.9	1.717779	1.678168	1.673320
10	1.0	1.784770	1.737869	1.732051

四、数值解法的误差估计、收敛性和稳定性

1. 定义 1

(1) 局部截断误差：假设 $y_i = y(x_i)$ ，按某方法由 y_i 严格算出 y_{i+1} 一步的误差，称为局部截断误差，记为 $R_{i+1} = y(x_{i+1}) - y_{i+1}$ 。

(2) 整体截断误差：去掉假设 $y_i = y(x_i)$ ，由 y_0 逐步严格计算出 y_{i+1} 的误差，称为整体截断误差，记为 $\varepsilon_{i+1} = y(x_{i+1}) - y_{i+1}$ 。

定义 2

若某种方法的局部截断误差为 $R_{i+1} = O(h^{p+1})$ ，则称该方法为 p 阶方法。

p 越大说明该方法的精确度越高。

2. Euler 方法的误差分析

对于初值问题, 当假设 y_i 是准确时, 用某种方法求 y_{i+1} 时所产生的截断误差, 就是该方法的局部截断误差。在第 $i+1$ 步使用 Euler 方法所得 y_{i+1} 的局部截断误差 $y(x_{i+1}) - y_{i+1}$ 。

假定 y_i 是准确的: 就是 $y_i = y(x_i)$

因为由 $y(x_{i+1}) = y(x_i + h) = y(x_i) + hy'(x_i) + \frac{h^2}{2}y''(\xi)$

而 $y_{i+1} = y_i + hf(x_i, y_i) = y(x_i) + hf(x_i, y_i) = y(x_i) + hy'(x_i)$

两式相减得 $y(x_{i+1}) - y_{i+1} = \frac{h^2}{2}y''(\xi) = O(h^2)$, 即 Euler 法的截断误差为 $O(h^2)$ 。 $\frac{h^2}{2}y''(\xi)$ 称为局部截断误差的主项。

设 y_i 是用某种方法计算初值问题(6-1)(6-2)在 x_i 点的近似解, 而 $y(x_i)$ 是它的精确解, 则 $\varepsilon_i = y(x_i) - y_i$ 就是该方法的整体截断误差, 也称为该方法的精度。若某方法的局部截断误差为 $O(h^{p+1})$, 则该方法的精度为 p 阶的。通过分析知道 Euler 方法的局部截断误差为 $O(h^2)$, 因此 Euler 方法的精度为一阶。

3. 收敛性,

定义: 对于某方法, 任意固定 $x_i = x_0 + ih$, 当 $h \rightarrow 0$ (同时 $i \rightarrow \infty$)时, 若有 $\varepsilon_i = [y(x_i) - y_i] \rightarrow 0$, 则称该方法收敛。

例: 就初值问题 $\begin{cases} y' = \lambda y \\ y(0) = y_0 \end{cases}$ 考察 Euler 显式公式的收敛性。

解: 该问题的精确解为 $y(x) = y_0 e^{\lambda x}$

Euler 公式为 $y_{i+1} = y_i + h\lambda y_i = (1 + h\lambda)y_i \Rightarrow y_i = (1 + h\lambda)^i y_0$

对任意固定的 $x = x_i = ih$, 有

$$y_i = y_0(1 + h\lambda)^{(x_i/h)} = y_0[(1 + h\lambda)^{(1/h)}]^{x_i}$$

$$\Rightarrow y_0 e^{\lambda x_i} = y(x_i)$$

4. 稳定性

定义: 用某方法固定步长 h 作计算, 由初值 y_0 严格得出 y_i , 现假设初值有微小误差 δ_0 , 即实际初值是 $y_0 + \delta_0$, 则引起第 i 步计算值有误差 δ_i , 即实际计算值为 $y_i + \delta_i$ 。若 $|\delta_i| \leq |\delta_0|$ ($i = 1, 2, \dots$), 则称该方法为关于步长 h 绝对稳定, 即 $|\delta_i|$ 不随着 i 无限扩大。

稳定性比较复杂, 所以一般分析时为简单起见, 只考虑试验方程 (test equation), 即 $y' = \lambda y$ 。

例: 对于 Euler 法

$$y_{i+1} = y_i + h(\lambda y_i) = (1 + \lambda h)y_i = (1 + \lambda h)(1 + \lambda h)y_{i-1} = \dots = (1 + \lambda h)^{i+1}y_0$$

设初值有小扰动 δ_0 , 则

$$y_{i+1} + \delta_{i+1} = (1 + \lambda h)^{i+1}(y_0 + \delta_0)$$

两式相减得

$$\delta_{i+1} = (1 + \lambda h)^{i+1}(\delta_0)$$

则, Euler 法绝对稳定 $\Leftrightarrow |1 + \lambda h| \leq 1$, 即 $h \leq -\frac{1}{\lambda}$ 时, Euler 方法绝对稳定。

§6.3 Runge-Kutta 方法

一、基本思想

根据 Lagrange 中值定理，知差商 $\frac{y(x_{i+1})-y(x_i)}{h} = y'(x_i + \theta h) = f(x_i + \theta h, y(x_i + \theta h))$

($0 \leq \theta \leq 1$)，转换得到解常微分方程的数值计算公式的一般形式 $y(x_{i+1}) = y(x_i) + hy'(x_i + \theta h) = y(x_i) + hf(x_i + \theta h, y(x_i + \theta h))$

其中， $f(x_i + \theta h, y(x_i + \theta h))$ 称为在区间 $[x_i, x_{i+1}]$ 上的平均变化率，记为 $K^* = f(x_i + \theta h, y(x_i + \theta h))$ 则，微分方程数值计算一般形式为： $y(x_{i+1}) = y(x_i) + hK^*$ 。

如果令 $K^* = f(x_i, y_i)$ ，得到 Euler 公式 $y(x_{i+1}) = y(x_i) + hf(x_i, y_i)$ 。而令 $k_1^* = f(x_i, y_i)$ ，

$k_2^* = f(x_{i+1}, y_{i+1})$ $K^* = \frac{1}{2}(k_1^* + k_2^*)$ ，梯形公式 $y(x_{i+1}) = y(x_i) + h((x_i, y_i) + f(x_{i+1}, y_{i+1}))$ 。

由于使用的信息更多，所以梯形公式的精度就更高。

从这个对比，可以考虑如果设法在 $[x_i, x_{i+1}]$ 上多找几个点的斜率值，将其加权平均，作为平均变化率 K^* 的值，可以构造出精度更高的计算公式，这种方法就是 Runge-Kutta 方法。

二、Runge-Kutta 方法基本思想

递推公式采用一般形式：

$$y(x_{i+1}) = y(x_i) + hK^*$$

在 $[x_i, x_{i+1}]$ 上多找几个点的斜率值，加权平均作为平均变化率 K^* ，

$$K^* = \sum_{j=1}^r \omega_j f(x_i + \alpha_j h, y_i + \beta_j h)$$

其中， ω_j 为权函数， r 是选取点的数量， α_j, β_j 是系数

Runge-Kutta 递推公式：

$$y(x_{i+1}) = y(x_i) + h \sum_{j=1}^r \omega_j f(x_i + \alpha_j h, y_i + \beta_j h)$$

r 指定之后， $\omega_j, \alpha_j, \beta_j$ 是待定的系数

二、2 阶 Runge-Kutta 公式

2 阶 Runge-Kutta 公式就是使用两个点的信息来做加权平均得到平均变化率 K^* 。根据 Runge-Kutta 方法递推公式

$$y_{i+1} = y_i + h \sum_{j=1}^r \omega_j f(x_i + \alpha_j h, y_i + \beta_j h)$$

取 $r=2$ ，得到：

$$\begin{aligned} y_{i+1} &= y_i + h\omega_1 f(x_i + \alpha_1 h, y_i + \beta_1 h) + h\omega_2 f(x_i + \alpha_2 h, y_i + \beta_2 h) \\ &= y_i + h\omega_1 f(x_i, y_i) + h\omega_2 f(x_i + \alpha h, y_i + \beta h) \end{aligned}$$

通过转换，可以写成：

$$\begin{cases} y_{i+1} = y_i + \omega_1 k_1^* + \omega_2 k_2^* \\ k_1^* = hf(x_i, y_i) \\ k_2^* = hf(x_i + \alpha h, y_i + \beta k_1^*) \end{cases}$$

其中 $\omega_1, \omega_2, \alpha, \beta$ 为待定参数。

用二元函数 Taylor 展开式展开

$$k_2^* = hf(x_i + \alpha h, y_i + \beta k_1^*) = h[f(x_i, y_i) + \alpha hf_x(x_i, y_i) + \beta k_1^* f_y(x_i, y_i) + O(h^2)] = hf(x_i, y_i) + h^2[\alpha f_x(x_i, y_i) + \beta f_y(x_i, y_i)f(x_i, y_i)] + O(h^3)$$

代入上式，得到

$$y_{i+1} = y_i + h(\omega_1 + \omega_2)f(x_i, y_i) + h^2[\alpha\omega_2 f_x(x_i, y_i) + \beta\omega_2 f_y(x_i, y_i)f(x_i, y_i)] + O(h^3)$$

其中 $\omega_1, \omega_2, \alpha, \beta$ 为待定参数

将待计算 y_{i+1} 对应的函数值 $y(x_{i+1})$ 进行 Taylor 展开

$$y(x_{i+1}) = y(x_i + h) = y(x_i) + hy'(x_i) + \frac{h^2}{2}y''(x_i) + O(h^3)$$

因为 $y'(x) = f(x, y)$ ， $y''(x) = f_x(x, y) + f_y(x, y)y'(x)$

$$\text{所以 } y(x_{i+1}) = y(x_i) + hy'(x_i) + \frac{h^2}{2}y''(x_i) + O(h^3) = y(x_i) + hy'(x_i) + \frac{h^2}{2}[f_x(x_i, y_i) + f_y(x_i, y_i)y'(x_i)] + O(h^3)$$

比较两个式子

$$y_{i+1} = y_i + h(\omega_1 + \omega_2)f(x_i, y_i) + h^2[\alpha\omega_2 f_x(x_i, y_i) + \beta\omega_2 f_y(x_i, y_i)f(x_i, y_i)] + O(h^3)$$

$$y(x_{i+1}) = y(x_i) + hy'(x_i) + \frac{h^2}{2}[f_x(x_i, y_i) + f_y(x_i, y_i)y'(x_i)] + O(h^3)$$

对应项相等， y_i 和 $y(x_i)$ 对应； $f(x_i, y_i)$ 跟 $y'(x_i)$ 对应，有 $h(\omega_1 + \omega_2) = h$ ； $f_x(x_i, y_i)$ 和 $f_x(x_i, y_i)$

对应，得 $h^2\alpha\omega_2 = \frac{h^2}{2}$ ； $f_y(x_i, y_i)f(x_i, y_i)$ 跟 $f_y(x_i, y_i)y'(x_i)$ 对应，得 $h^2\beta\omega_2 = \frac{h^2}{2}$ 。

$$\text{所以，得} \begin{cases} \omega_1 + \omega_2 = 1 \\ \alpha\omega_2 = \frac{1}{2} \\ \beta\omega_2 = \frac{1}{2} \end{cases}$$

$$\text{当} \begin{cases} \omega_1 + \omega_2 = 1 \\ \alpha\omega_2 = \frac{1}{2} \\ \beta\omega_2 = \frac{1}{2} \end{cases} \text{成立时，} y(x_{i+1}) - y_{i+1} = O(h^3)$$

满足等式的解有无穷多，对应于两点情况的 Runge-Kutta 公式均具有二阶精度，统称为二阶 Runge-Kutta 公式。

如：取 $\alpha=1, \beta=1, \omega_1=\omega_2=\frac{1}{2}$ 是 Euler 预报-校正公式

如：取 $\alpha=\beta=1, \omega_1=0, \omega_2=1$ ，则得到如下 Runge-Kutta 公式

$$\begin{cases} y_{i+1} = y_i + k_2^* \\ k_1^* = hf(x_i, y_i) \\ k_2^* = hf(x_i + h, y_i + k_1^*) \end{cases}$$

三、3 阶 Runge-Kutta 公式

使用跟两点情况相同的推导方法，得

$$\begin{cases} y_{i+1} = y_i + \frac{1}{6}(k_1 + 4k_2 + k_3) \\ k_1 = hf(x_i, y_i) \\ k_2 = hf\left(x_i + \frac{h}{2}, y_i + \frac{k_1}{2}\right) \\ k_3 = hf(x_i + h, y_i - k_1 + 2k_2) \end{cases}$$

局部截断误差为 $O(h^4)$

四、4 阶 Runge-Kutta 公式

$$\begin{cases} y_{i+1} = y_i + \frac{1}{6}(k_1 + 2k_2 + 2k_3 + k_4) \\ k_1 = hf(x_i, y_i) \\ k_2 = hf\left(x_i + \frac{h}{2}, y_i + \frac{k_1}{2}\right) \\ k_3 = hf\left(x_i + \frac{h}{2}, y_i + \frac{k_2}{2}\right) \\ k_4 = hf(x_i + h, y_i + k_3) \end{cases}$$

此公式又称为经典的 Runge-Kutta 公式

局部截断误差为 $O(h^5)$

例 6 用经典的 Runge-Kutta 法计算 $\begin{cases} y' = y - 2x/y, x \in [0, 0.9] \\ y(0) = 1 \end{cases}$

取步长 $h = 0.2$

解：由 $x_0 = 0, y_0 = 1, h = 0.2$ ，利用 4 阶 Runge-Kutta 公式可计算出

$$k_1 = hf(x_0, y_0) = 0.2(1 - (2 \times 0)/1) = 0.2$$

$$k_2 = hf\left(x_0 + \frac{h}{2}, y_0 + \frac{k_1}{2}\right) = 0.2f(0.1, 1.1) = 0.18364$$

$$k_3 = hf\left(x_0 + \frac{h}{2}, y_0 + \frac{k_2}{2}\right) = 0.2f(0.1, 1.09182) = 0.18173$$

$$k_4 = hf(x_0 + h, y_0 + k_3) = 0.2f(0.2, 1.18173) = 0.16965$$

$$\text{得到：} y_1 = y_0 + (k_1 + k_2 + k_3 + k_4)/4 = 1.18323$$

Runge-Kutta 法的主要运算在于计算 K_i 的值，即计算 f 的值。Butcher 于 1965 年给出了计算量与可达到的最高精度阶数的关系：由于 Runge-Kutta 法的导出基于泰勒展开，故精度主要受解函数的光滑性影响。对于光滑性不太好的解，最好采用低阶算法而将步长 h 取比较小的值。

§6.4 Adams 方法

一. 一般线性多步法

由于在计算 y_{n+1} 时，已经知道 y_n, y_{n-1}, \dots ，及 $f(x_n, y_n), f(x_{n-1}, y_{n-1}), \dots$ ，利用多于一个节点的这些值构造出精度高、计算量小的差分公式就是线性多步法。即用若干节点处的 y 及 y' 值的线性组合来近似 $y(x_{i+1})$ 。

其通式可写为：

$$y_{i+1} = \alpha_0 y_i + \alpha_1 y_{i-1} + \dots + \alpha_k y_{i-k} + h(\beta_{-1} f_{i+1} + \beta_0 f_i + \beta_1 f_{i-1} + \dots + \beta_k f_{i-k})$$

当 $\beta_{-1} \neq 0$ 时，为隐式公式； $\beta_{-1} = 0$ 则为显式公式。

基于数值积分的构造法

将 $y' = f(x, y)$ 在 $[x_i, x_{i+1}]$ 上积分, 得到 $y(x_{i+1}) - y(x_i) = \int_{x_i}^{x_{i+1}} f(x, y(x)) dx$

只要近似地算出右边的积分 $I_k = \int_{x_i}^{x_{i+1}} f(x, y(x)) dx$, 则可通过 $y_{i+1} = y_i + I_k$ 近似 $y(x_{i+1})$ 。

而选用不同近似式 I_k , 可得到不同的计算公式。

二. Adams 显式公式 (Adams explicit formule)

利用 $k+1$ 个节点上的被积函数值 $f_i, f_{i-1}, \dots, f_{i-k}$ 构造 k 阶牛顿后插多项式 $N_k(x_i + th), t \in [0, 1]$ 有

$$\int_{x_i}^{x_{i+1}} f(x, y(x)) dx = \int_0^1 N_k(x_i + th) h dt + \int_0^1 R_k(x_i + th) h dt$$

$$\Rightarrow y_{i+1} = y_i + h \int_0^1 N_k(x_i + th) dt$$

局部截断误差为:

$$R_i = y(x_{i+1}) - y_{i+1} = h \int_0^1 R_k(x_i + th) dt$$

例: $k = 1$ 时有

$$N_1(x_i + th) = f_i + t \nabla f_i = f_i + t(f_i - f_{i-1})$$

导出

$$y_{i+1} = y_i + h \int_0^1 [f_i + t(f_i - f_{i-1})] dt = y_i + \frac{h}{2} (3f_i - f_{i-1})$$

所以

$$R_i = h \int_0^1 \frac{d^2 f(\xi_x, y(\xi_x))}{dx^2} \frac{1}{2} th(t+1) h dt = \frac{5}{12} h^3 y'''(\xi_i)$$

注: 一般有 $R_i = B_k h^{k+2} y^{(k+2)}(\xi_i)$, 其中 B_k 与 y_{i+1} 计算公式中 f_i, \dots, f_{i-k} 各项的系数均可查表得到。

k	f_i	f_{i-1}	f_{i-2}	f_{i-3}	\dots	B_k
0	1					$\frac{1}{2}$
1	$\frac{3}{2}$	$-\frac{1}{2}$				$\frac{5}{12}$
2	$\frac{23}{12}$	$-\frac{16}{12}$	$\frac{5}{12}$			$\frac{3}{8}$
3	$\frac{55}{24}$	$-\frac{59}{24}$	$\frac{37}{24}$	$-\frac{9}{24}$		$\frac{251}{720}$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots

常用的是 $k = 3$ 的 4 阶 Adams 显式公式

$$y_{i+1} = y_i + \frac{h}{24} (55f_i - 59f_{i-1} + 37f_{i-2} - 9f_{i-3})$$

三. Adams 隐式公式(Adams implicit formule)

利用 $k + 1$ 个节点上的被积函数值 $f_{i+1}, f_i, f_{i-1}, \dots, f_{i-k+1}$ 构造 k 阶牛顿前插多项式。与显式多项式完全类似地可得到一系列隐式公式, 并有 $R_i = B_k h^{k+2} y^{(k+2)}(\eta_i)$, 其中 B_k 与 $f_{i+1}, f_i, \dots, f_{i-k+1}$ 的系数亦可查表得到。

k	f_{i+1}	f_i	f_{i-1}	f_{i-2}	\dots	\widetilde{B}_k
0	1					$-\frac{1}{2}$
1	$\frac{1}{2}$	$\frac{1}{2}$				$-\frac{1}{12}$
2	$\frac{5}{12}$	$\frac{8}{12}$	$-\frac{1}{12}$			$-\frac{1}{24}$
3	$\frac{9}{24}$	$\frac{19}{24}$	$-\frac{5}{24}$	$\frac{1}{24}$		$-\frac{19}{720}$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots

常用的是 $k = 3$ 的 4 阶 Adams 隐式公式

三. Adams 预测-校正系统(Adams predictor-corrector system)

Step 1: 用 Runge-Kutta 法计算前 k 个初值;

Step 2: 用 Adams 显式计算预测值;

Step 3: 用同阶 Adams 隐式计算校正值。

注意: 三步所用公式的精度必须相同。通常用经典 Runge-Kutta 法配合 4 阶 Adams 公式

§6.5 实用工具

ode23, ode45, ode113, ode15s, ode23s, ode23t, ode23tb

函数	ODE类型	特点	说明
ode45	非刚性	单步法; 4, 5 阶 R-K 方法; 累计截断误差为 $(\Delta x)^3$	大部分场合的首选方法
ode23	非刚性	单步法; 2, 3 阶 R-K 方法; 累计截断误差为 $(\Delta x)^3$	使用于精度较低的情形
ode113	非刚性	多步法; Adams算法; 高低精度均可到 $10^{-3} \sim 10^{-6}$	计算时间比 ode45 短
ode23t	适度刚性	采用梯形算法	适度刚性情形
ode15s	刚性	多步法; Gear's 反向数值微分; 精度中等	若 ode45 失效时, 可尝试使用
ode23s	刚性	单步法; 2 阶 Rosebrock 算法; 低精度	当精度较低时, 计算时间比 ode15s 短
ode23tb	刚性	梯形算法; 低精度	当精度较低时, 计算时间比ode15s短

采用自动的变步长方法

命令格式

`[T, Y, TE, YE, IE] = solver(odefun, tspan, y0, options)`

odefun: $f(t, y)$, 可以是列向量 (方程组)

tspan: 区间端点 $[t_0, t_f]$, 或值递增/递减的向量 $[t_0, t_1, \dots, t_f]$

若不设返回值, 自动进入绘图模式, 绘出解函数

T: 时间点向量; Y: 这些点上的函数近似值

相关命令: odeset (用于设置 options)

§6.5 实用工具

例 5.1 当点燃一根火柴时, 火焰迅速增大直到一个临界体积, 然后维持这一体积不变, 此时火焰内部燃烧消耗的氧气和其表面现存的氧气达到了一种平衡.

火焰(近似为球)半径 y 满足 ODE

$$\begin{cases} y' = y^2 - y^3 \\ y(0) = \eta \end{cases}, \eta \text{ 是初始半径, 设为 } \eta = 0.0001$$

```
>> f = @(t,y) y^2 - y^3;
```

```
>> ode23(f, [0, 2.0e4], 1e-4)
```

§6.5 实用工具

例 5.2

求解 $n=2$ 的一阶常微分方程组 $\begin{cases} y' = f(t, y) \\ y(t_0) = y_0 \end{cases}$

$$\begin{cases} y'_1 = y_2 \\ y'_2 = 6t \end{cases}, y_1(0) = 0, y_2(0) = 1$$

定义函数

```
>>ode23(@myode2, [0, 1], [0; 1]);
```

作业:

P164: 1

用 Euler 法、预报-校正法求 $\begin{cases} y' = -y \\ y(0) = 1 \end{cases}, x \in [0, 1.0]$ 的数值解, 取 $h = 0.1$, 结果保留四位小数。

3. 用预报-校正法求 $\begin{cases} y' = x^2 \\ y(0) = 0 \end{cases}, x \in [0, 2]$ 的数值解, 取 $h = 0.5$, 结果保留四位小数; 并与精

确解 $y = \frac{1}{3}x^3$ 作比较。

参考文献：

1. 李庆扬，王能超，易大义，数值分析，第 4 版，华中科技大学出版社，武汉，2006
2. 关治，陈景良，数值计算方法，清华大学出版社，北京，1990
3. 喻文健，数值分析与算法，第 2 版，清华大学出版社，北京，2015